

# TD $N^{\underline{o}}3$ : Analyse des Correspondances Multiples Analyse exploratoire

Auteurs: Manelle Nouar, Eliott Bernardou, Sarra Madad, Mohamed Abdelkader, Alfio Chadoin

Enseignants: Myriam Bertrand & Jordan Gonzalez

## 1 | Pokemon

## 1.1 Questions/Réponses

1. Téléchargez la bibliothèque ade4 et la bibliothèque adegraphics.

```
library (ade4)
library (adegraphics)
library (PCAmixdata)
library (vcd)
library (corrplot)
library (factoextra)
library (FactoMineR)
```

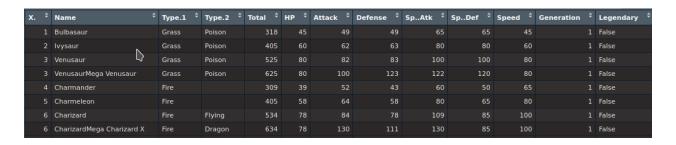
2. Chargez les données du fichier pokemon.csv disponible à l'adresse https: tinyurl.com/y4y6a86m.

```
1 pokemon = read.csv2("/cloud/project/pokemon.csv", sep = ",")
```

3. Associez ce jeu de données à un jeu de données de type data.frame que vous appelerez poke.

```
poke = as.data.frame(pokemon)

View(poke)
str(poke)
names(poke)
attach(poke)
summary(poke)
dim(poke)
colnames(poke)
row.names(poke)
```



```
data.frame':
                      800 obs. of 13 variables:
                            "Bulbasaur" "Tysaur" "Venusaur" "VenusaurMega Venusaur" ...
$ Name
                            "Grass" "Grass" "Grass" "Grass" ...
"Poison" "Poison" "Poison" "Poison"
$ Type.1
                    chr
$ Type.2
                    chr
                            318 405 525 625 309 405 534 634 634 314 ...
  Total
                           45 60 80 80 39 58 78 78 78 44 ...
49 62 82 100 52 64 84 130 104 48 ...
49 63 83 123 43 58 78 111 78 65 ...
                    int
  Attack
                    int
  Defense
                           65 80 100 122 60 80 109 130 159 50 ...
65 80 100 120 50 65 85 85 115 64 ...
  Sp..Def
                           45 60 80 80 65 80 100 100 100 43 ...
1 1 1 1 1 1 1 1 1 1 ...
"False" "False" "False" "False" ...
  Speed
                 : int
  Generation: int
   Legendary : chr
                                                                                                      "HP"
                                                                                                                          "Attack
                                                                                    "Generation" "Legendary"
```

En regardant le type de certaines variables, nous allons devoir les transformer en facteur pour pouvoir les utiliser. Le type facteur, facilite la manipulation de données qualitatives (qu'elles soient numériques ou caractères). En effet, en plus de stocker les différents éléments comme un vecteur classique, il stocke également l'ensemble des différentes modalités possibles dans un attribut.

4. Transformez la variable Generation en type factor.

```
poke$Generation = as.factor(poke$Generation)
summary(poke)
```

```
Total
                   Name
                                      Type.1
                                                         Type.2
      : 1.0
                                                                               :180.0
Min.
                Length:800
                                   Length:800
                                                      Length:800
                                                                         Min.
1st Qu.:184.8
                Class :character
                                   Class :character
                                                      Class :character
                                                                         1st Qu.:330.0
Median :364.5
                Mode :character
                                   Mode :character
                                                      Mode :character
                                                                         Median :450.0
Mean :362.8
                                                                         Mean :435.1
3rd Qu.:539.2
                                                                         3rd Qu.:515.0
     :721.0
HP
                                                                         Max.
                                                                                :780.0
Max.
                    Attack
                                  Defense
                                                                    Sp..Def
                                                                                     Speed
         1.00
                               Min. : 5.00
                                                Min. : 10.00
                                                                       : 20.0
                               1st Ou.: 50.00
1st Qu.: 50.00
                1st Ou.: 55
                                                                 1st Ou.: 50.0
                                                1st Ou.: 49.75
                                                                                 1st Ou.: 45.00
Median : 65.00
                                                Median : 65.00
                                                                                 Median : 65.00
                Median: 75
                               Median : 70.00
                                                                 Median : 70.0
                                                                        : 71.9
Mean
      : 69.26
                Mean : 79
                               Mean : 73.84
                                                Mean : 72.82
                                                                 Mean
                                                                                 Mean
                                                                                       : 68.28
                                                3rd Qu.: 95.00
3rd Qu.: 80.00
                 3rd Qu.:100
                               3rd Qu.: 90.00
                                                                 3rd Qu.: 90.0
                                                                                 3rd Qu.: 90.00
Max.
      :255.00
                Max.
                       :190
                               Max.
                                     :230.00
                                                Max.
                                                      :194.00
                                                                 Max.
                                                                       :230.0
                                                                                 Max.
                                                                                       :180.00
Generation Legendary
          Length:800
2:106
          Class :character
3:160
          Mode :character
5:165
6: 82
```

Nous pouvons maintenant voir que la variable Generation est bien affiché.

5. Créez un sous jeu de données composé exclusivement des variables suivantes : Type<sub>1</sub>, Generation et Legendary.

```
1 poke.x = poke [, c(3,12,13)]
```



Nous créons notre jeu de données et on sélectionne bien le rang des variables Type 1 (rang 3), Generation (rang 12) et Legendary (rang 13).

6. Appliquez la fonction summary() au jeu de données poke, de type data.frame.

```
1 summary(poke)
2 summary(poke.x)
```

```
Type.1
                                                           Type.2
                                                                                Total
                                                                                                                   Attack
                                                                                                                                Defense
                                    Length:800
                                                                            Min. :180.0
                Length:800
                                                        Length:800
1st Qu.:184.8
                Class :character
                                    Class :character
                                                        Class :character
                                                                            1st Qu.:330.0
                                                                                             1st Qu.: 50.00
                                                                                                               1st Qu.: 55
                                                                                                                             1st Qu.: 50.00
                                                                                                                             Median : 70.00
Mean : 73.84
Median :364.5
                Mode :character
                                    Mode :character
                                                        Mode :character
                                                                            Median :450.0
                                                                                             Median : 65.00
                                                                                                              Median : 75
                                                                            Mean :435.1
                                                                                             Mean : 69.26
                                                                                                              Mean : 79
Mean :362.8
3rd Qu.:539.2
                                                                             3rd Qu.:515.0
                                                                                             3rd Qu.: 80.00
                                                                                                               3rd Qu.:100
                                                                                                                             3rd Qu.: 90.00
      :721.0
                                                                                                    :255.00
   Sp..Atk
                    Sp..Def
                                      Speed
                                                    Generation Legendary
Min. : 10.00
1st Qu.: 49.75
                 Min. : 20.0
1st Qu.: 50.0
                                  Min. : 5.00
                                                    1:166
                                                               Lenath:800
                                  1st Qu.: 45.00
                                                    2:106
                                                               Class :character
Median : 65.00
                  Median : 70.0
                                  Median : 65.00
                                                    3:160
                                                                Mode :character
Mean : 72.82
                  Mean : 71.9
                                  Mean
                                         : 68.28
                 3rd Qu.: 90.0
Max. :230.0
3rd Ou.: 95.00
                                  3rd Qu.: 90.00
                                                    5:165
Max. :194.00
                                  Max.
                                         :180.00
                   Generation Legendary
Lenath:800
                   1:166
                               Lenath:800
Class :character
                   2:106
                               Class :character
Mode :character
                               Mode :character
                   5:165
                    6: 82
```

Nos variables sont maintenant bien formatés et prêtes à être utilisés.

7. À l'aide de la bibliothèque ade4 et de la bibliothèque adegraphics, appliquez la fonction dudi.acm() au jeu de données poke.x.

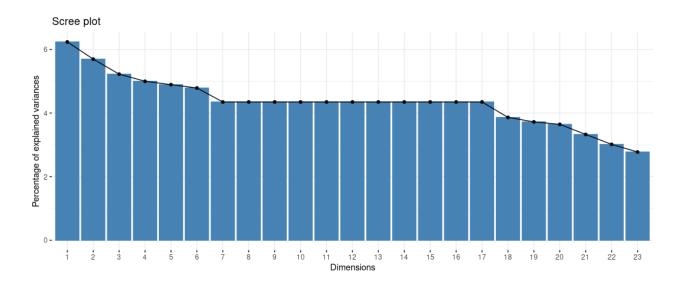
```
poke.x$Type.1 = as.factor(poke$Type.1)
poke.x$Legendary = as.factor(poke$Legendary)
summary(poke.x)
res.acm.poke = dudi.acm(poke.x,scannf=FALSE)
res.acm.poke
```

```
Duality diagramm
class: acm dudi
$call: dudi.acm(df = poke.x, scannf = FALSE)
$nf: 2 axis-components saved
$rank: 23
eigen values: 0.478 0.4366 0.4004 0.3832 0.375 ...
 vector length mode
                      content
               numeric column weights
1 $cw
         26
2 $lw
         800
                numeric row weights
3 $eig
                numeric eigen values
  data.frame nrow ncol content
1 $tab
             800 26 modified array
2 $li
             800
                       row coordinates
             800
                       row normed scores
  $co
             26
                      column coordinates
5 $c1
                       column normed scores
other elements: cr
```

Pour utiliser la fonction dudi.acm(), nous avons dû transformer toutes les variables en facteur. Cette fonction effectue l'analyse des correspondances multiples d'une table de facteurs.

8. Sauriez-vous dire le nombre total de valeurs propres ? Affichez les valeurs propres avec la fonction fvizscreeplot() du package ade4.

```
fviz_screeplot(res.acm.poke, ncp=23)
get_eig(res.acm.poke)
```



Sur cette figure, nous pouvons voir qu'il y a une dimension de 23, donc 23 valeurs propres. Par défaut, la figure affiche 10 dimension. Nous avons dû ajouter un paramètre (ncp) pour pouvoir afficher toutes les dimensions.

Si on met ncp = 50 on a encore que 23 valeurs propres qui s'affichent, je pense, c'est plus logique que ncp=23 vu que techniquement le 23 on ne le connait pas encore à cette étape.

	eigenvalue		cumulative.variance.percent
Dim.1	0.4780316	6.235195	6.235195
Dim.2	0.4365931	5.694692	11.929888
Dim.3	0.4003682	5.222194	17.152081
Dim.4	0.3831707	4.997879	22.149961
Dim.5	0.3750273	4.891660	27.041621
Dim.6	0.3670084	4.787066	31.828686
Dim.7	0.3333333	4.347826	36.176512
Dim.8	0.3333333	4.347826	40.524338
Dim.9	0.3333333	4.347826	44.872165
Dim.10	0.3333333	4.347826	49.219991
Dim.11	0.3333333	4.347826	53.567817
Dim.12	0.3333333	4.347826	57.915643
Dim.13	0.3333333	4.347826	62.263469
Dim.14	0.3333333	4.347826	66.611295
Dim.15	0.3333333	4.347826	70.959121
Dim.16	0.3333333	4.347826	75.306947
Dim.17	0.3333333	4.347826	79.654773
Dim.18	0.2961106	3.862313	83.517086
Dim.19	0.2853067	3.721391	87.238477
Dim.20	0.2794082	3.644455	90.882932
Dim.21	0.2550264	3.326432	94.209364
Dim.22	0.2311516	3.015021	97.224384
Dim.23	0.2127972	2.775616	100.000000

Nous pouvons affirmer, qu'il y a bien 23 valeurs propres.

9. Affichez et interprétez les rapports de corrélation pour le premier et le deuxième axe (en utilisant la liste de l'objet res.acm.poke).

```
score(res.acm.poke,xax=1, type="boxplot")
head(inertia.dudi(res.acm.poke) $tot)
scatter(res.acm.poke)
get_mca_var(res.acm.poke) $contrib
res.acm.poke$cr
```

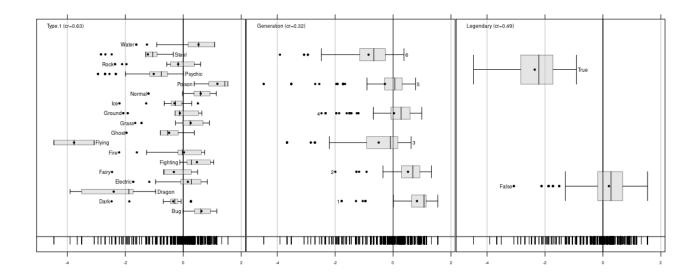
```
res.acm.poke$c1

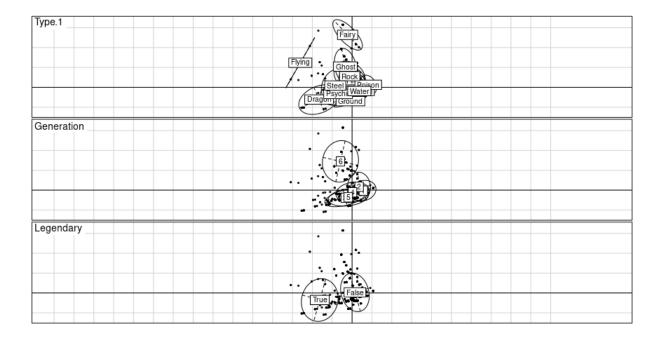
barplot(res.acm.poke$cr[,1], names.arg=row.names(res.acm.poke$cr),

las=2, main="Premiere axe", col = "blue")

barplot(res.acm.poke$cr[,2], names.arg=row.names(res.acm.poke$cr),

las=2, main="Deuxieme axe", col = "blue")
```





Les Pokémon légendaire sont principalement de type Flying, Dragon et steel. Ils sont de génération 5 et 6. Et légendaire qui vaut true.



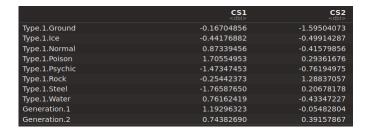




Nous remarquons que Type.1 est à l'origine de l'axe 1 et de l'axe 2. En second lieu, Génération participe à la construction de l'axe 2. Legendary, participe a la formation de l'axe 1.



Le type Dragon a une influence négative de 3.47 sur le 1er axe. Le type Flying a une influence négative de 5.45 sur le 1er axe.



Le type Steel a une influence négative de 1.76 sur le 1er axe.

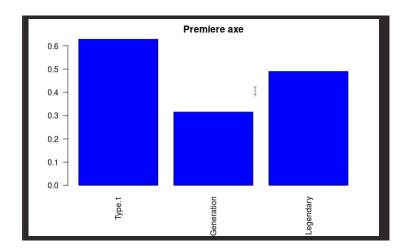


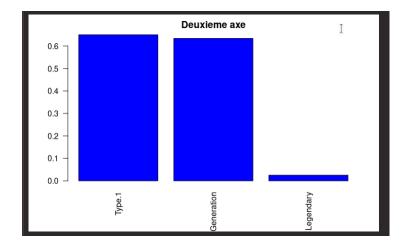
L'attribut légendaire a une influence négative de 3.40 sur le 1er axe.

La 3e génération a une influence négative de 0.82 sur le 1er axe.

La 5e génération a une influence négative de 0.82 sur le 1er axe.

La 6e génération a une influence positive de 0.82 sur le 2e axe.





10. Quelles modalités des trois facteurs décrivent le mieux le premier axe?

Nous pouvons en conclure, que les modalités des trois facteurs qui décrivent le mieux l'axe 1 sont :

- Type. 1 = Dragon.
- Generation = 1.
- Legendary = True.
- 11. À l'aide de la bibliothèque vcd, utilisez la fonction assocstats() sur votre sous jeu de données (attention il faut le transformer en tableau de contingence avant). Commentez.

```
1   assocstats(table(poke.x))
2
3   t1 = table(poke.x[,1], poke.x[,2])
4   assocstats(t1)
5
6   t2 = table(poke.x[,1], poke.x[,3])
7   assocstats(t2)
```

```
8
9 t3 = table(poke.x[,2], poke.x[,3])
10 assocstats(t3)
```

```
$`Legendary:False
                    X^2 df P(> X^2)
Likelihood Ratio 170.31 85 1.1698e-07
                 177.69 85 1.6370e-08
Phi-Coefficient : NA
Contingency Coeff.: 0.441
Cramer's V
                  : 0.22
$`Legendary:True`
                    X^2 df P(> X^2)
Likelihood Ratio 89.428 85 0.35017
Pearson
                    NaN 85
Phi-Coefficient : NA
Contingency Coeff.: NaN
Cramer's V
                   X^2 df P(> X^2)
Likelihood Ratio 186.13 85 1.5924e-09
                 184.65 85 2.4126e-09
Phi-Coefficient : NA
Contingency Coeff.: 0.433
Cramer's V
                 : 0.215
                   X^2 df P(> X^2)
Likelihood Ratio 76.183 17 1.8115e-09
                 90.420 17 5.1186e-12
Pearson
Phi-Coefficient : NA
Contingency Coeff.: 0.319
                    X^2 df P(> X^2)
Likelihood Ratio 10.9164 5 0.053063
Pearson 9.8768 5 0.078803
Phi-Coefficient : NA
Contingency Coeff.: 0.11
Cramer's V
                  : 0.111
```

#### Règle de décision :

- Si  $\rho \le \alpha$  : les variables présentent une association statistiquement significative donc on rejette  $H_0$ .
- Si  $\rho > \alpha$ : on ne possédez pas suffisamment de preuves pour conclure que les variables sont associées, donc on ne pas rejeter  $H_0$ .

Notre p valeur est plus petite que 0.05, quand Legendary est à False. Cela veut dire, qu'il n'existe aucun lien entre les Pokémon Légendaire, le type de Pokémon et la génération de Pokémon.

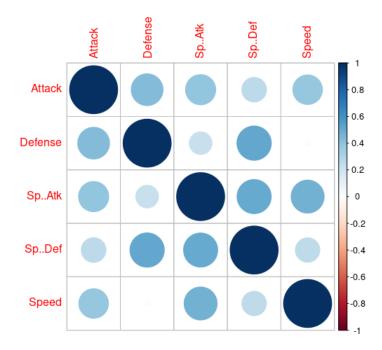
Notre p valeur est plus grande que 0.05, quand Legendary est à True. Cela veut dire, qu'il existe un lien entre les Pokémon Légendaire, le type de Pokémon et la génération de Pokémon.

Pour conclure, il est logique que les Pokémon communs (non légendaires) soient indépendants aux types et générations, car il y en a énormément.

12. Affichez la matrice de corrélation sur les variables quantitatives suivantes : Attack, Defense, Sp..Atk, Sp..Def et Speed.

```
1 c = cor(poke[c("Attack", "Defense", "Sp.. Atk", "Sp.. Def", "Speed")])
2 corrplot(c)
```

```
Attack Defense Sp..Atk Sp..Def Speed Attack 1.0000000 0.4386871 0.3963618 0.2639896 0.3812397 Defense 0.4386871 1.0000000 0.2235486 0.5107466 0.0152266 Sp..Atk 0.3963618 0.2235486 1.0000000 0.5061214 0.4730179 Sp..Def 0.2639896 0.5107466 0.5061214 1.0000000 0.2591331 Speed 0.3812397 0.0152266 0.4730179 0.2591331 1.0000000
```



Les couples de variables suivant ont une forte corrélation positive :

- Defense et Attack.
- Sp..Def et Defense.
- Sp..Def et SP Atk.

etc.

Le couple suivant n'a pas de corrélation : Speed et Defense.

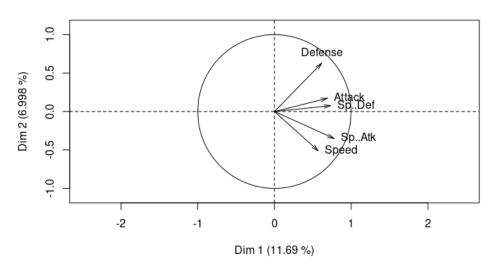
- 13. Téléchargez la bibliothèque PCAmixdata et chargez-là.
- 14. Appliquez la fonction PCAmix() sur les variables quantitatives suivante : Attack,Defense,Sp..Atk,Sp..Def,Speed et la variable qualitative : Type1.

```
pcamix.temp <- PCAmix(subset(poke, select=c(7:11)), subset(poke, select=c(3)))

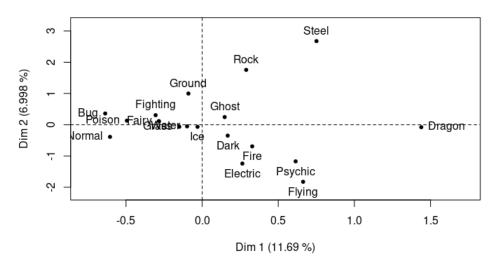
pcamix.poke <- PCAmix(poke[c("Attack", "Defense", "Sp.. Atk", "Sp.. Def", "Speed")],

poke[c("Type.1")])
```





## Levels component map

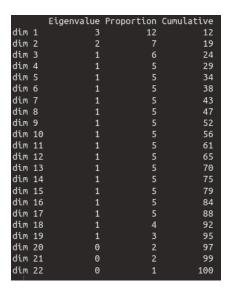


Nous effectuons une analyse en composantes principales d'un ensemble de Pokémon décrits par un mélange de variables qualitatives et quantitatives. PCAmix comprend l'analyse en composantes principales ordinaire (PCA) et l'analyse des correspondances multiples (MCA) comme cas particuliers.

Les Pokémon de type Psychic, Fire et Electric ont tendances à être rapide. Les Pokémon de type Steel et Rock ont tendance à être fort en défense.

### 15. Affichez les valeurs propres.

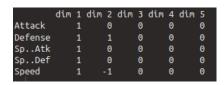
print(round(pcamix.temp\$eig))
print(round(pcamix.poke\$eig))



Nous affichons dans cette question les valeurs propres.

16. Affichez les corrélations des variables quantitatives suivantes : Attack, Defense, Sp.. Atk, Sp.. Def, Speed.

```
print(round(pcamix.temp$quanti.cor))
print(round(pcamix.poke$quanti.cor))
```

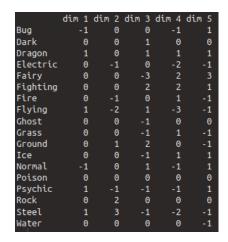


Nous affichons dans cette question les corrélations. Elles vont de -1 à 1.

O signifie qu'il y a une absence de corrélation avec la dimension.

- 1 qu'il y a une corrélation positive forte avec la dimension.
- -1 une corrélation négative forte avec la dimension.
- 17. Affichez les coordonnées des modalités de la variable qualitative : Type1. Si vous n'arrivez pas à répondre à ces cinq questions, voici les commandes qui vous permettraient d'y répondre.

```
print(round(pcamix.temp$categ.coord))
print(round(pcamix.poke$categ.coord))
```

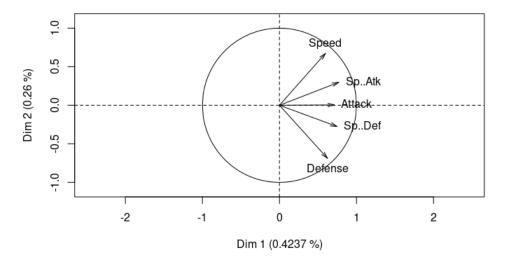


Nous affichons dans cette question les modalités de la variable qualitative Type 1.

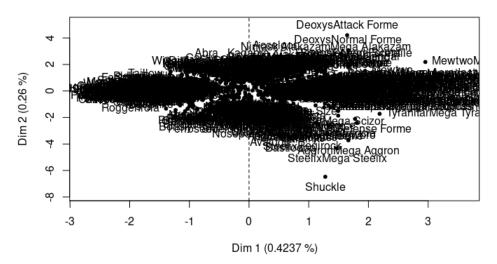
18. Réalisez cette A.C.P. mixte en remplaçant le facteur Type1 par le nom des pokemons.

```
1 acp = PCAmix(subset(poke, select=7:11), subset(poke, select=2))
```

## Correlation circle



## Levels component map



19. Observez et commentez les coordonnées du pokemon Pikachu sur l'A.C.P. mixte.

```
1 acp[["levels"]][["coord"]]["Pikachu",]
2 acp$quanti.cor
```

dim 1	dim 2	dim 3	dim 4	dim 5
-0.783122996	1.151944208	0.008491054	1.016673653	0.152459138

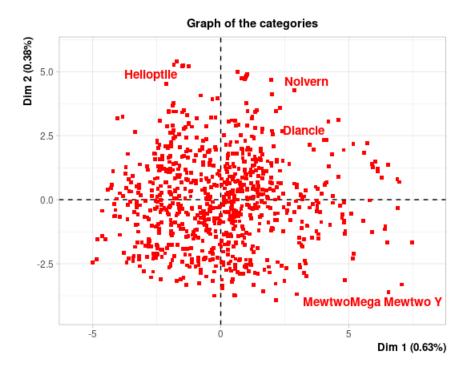
```
Attack
        0.7137138
                   0.004122036
                                 0.63951379
Defense 0.6230973
                   -0.687486286
                                 0.14686705
                   0.297991012
                                -0.28278644
Sp..Def
        0.7475578
                   -0.275418689
                                -0.49617062
                   0.672958390
        0.5970917
                                 0.06827486
Speed
             dim 5
Defense
         0.3116844
         0.1765239
Sp..Atk
Sp..Def
         0.3041973
         0.1172321
```

Pikachu est fortement corrélé de manière positive dans l'axe 2 et l'axe 4. La commande acp\$quanti.cor montre que pikachu n'a pas une bonne defense mais une bonne vitesse (en dim 2), la dim 4 montre qu'il n'a pas une bonne attaque spé mais une bonne vitesse.

20. Appliquez la fonction FAMD() au jeu de données poke. Observez le résultat avec la fonction summary().

```
fd = FAMD(poke, graph = TRUE, axes = c(1,2), ncp = 23)
summary(fd)
```

```
Eigenvalues
                                                                            I
                     Dim.1 Dim.2 Dim.3 Dim.4 Dim.5 Dim.6
Variance
                     5.328 3.252 2.871 2.554 2.522 2.441
% of var.
                     0.628 0.383 0.339 0.301 0.297 0.288
Cumulative % of var. 0.628 1.012 1.350 1.652 1.949 2.237
                     Dim.7 Dim.8 Dim.9 Dim.10 Dim.11
                                        2.288
Variance
                     2.338 2.325 2.302
% of var.
                     0.276 0.274 0.271
                                        0.270
                                               0.265
Cumulative % of var. 2.513 2.787 3.058
                                        3.328
                                               3.593
                     Dim.12 Dim.13 Dim.14 Dim.15 Dim.16
Variance
                      2.235
                            2.200
                                    2.190
                                           2.168
% of var.
                      0.264
                            0.259
                                    0.258
Cumulative % of var.
                      3.857
                             4.116
                                    4.375
                                           4.630
                                                  4.884
                     Dim.17 Dim.18 Dim.19 Dim.20 Dim.21
Variance
                      2.125
                             2.119
                                    2.079
                                           2.068
                                                  2.046
                      0.251
                             0.250
                                    0.245
                                           0.244
Cumulative % of var.
                      5.135
                             5.385
                                    5.630
                                           5.874
                                                  6.115
                     Dim.22 Dim.23
Variance
                      2.005
                            1.983
                      0.236
% of var.
                             0.234
Cumulative % of var. 6.351
                             6.585
Individuals (the 10 first)
                                      Dim.1
                            29.034 |
                                     -2.728
                                             0.175
                            28.977
                                     -1.336
                                             0.042
```



Eigenvalues : Tableau avec les valeurs propres, le pourcentage de variance et le pourcentage cumulée de variance.

Individuals : matrice avec les coordonnées, le carré du cosinus (cos2) et la contribution de chaque dimension des valeurs propres.

Categories : matrice avec les coordonnées, le carré du cosinus (cos2), la contribution et le V de cramer de chaque pokemon.

#### 21. Expliquez ce qu'est la fonction FAMD() et son utilité.

Le Multiple Factor Analysis for Mixed Data (AFDM), nous permet d'effectuer une analyse factorielle

multiple avec des données quantitatives et qualitatives. Nous pouvons donc utiliser l'AFDM sur des variables quantitatives et qualitatives, contrairement à une AFC ou ACP.